HyperDesign 2.0 —— 面向制造落地的自进化工业设计智能体平台

作品介绍（2.0 版）· 把生成式造型深度装进平台化工程骨架

项目编号：proj_20261014_001 ｜ 示范产品：工业级无线振动/温湿度三合一传感器外壳（120×80×45mm，PC+ABS 上盖 + 铝合金 CNC 底座）

申报赛道：第三届"兴智杯"全国人工智能创新应用大赛 · 解决方案赛 · 行业赋能

1.0 版本记录：见仓库 `docs/作品介绍_HyperDesign.pdf`；2.0 增量：平台层（智能体/技能/准入/工作流/界面）、CAE、知识资产与六道工程门禁。

全本地部署 | 受控几何中间表示 | 工艺规则可审计 | 物理信号一票否决 | 自研有限元 | 知识资产 + RBAC | 偏好自进化 + 守门员 | 单机 16GB 可跑

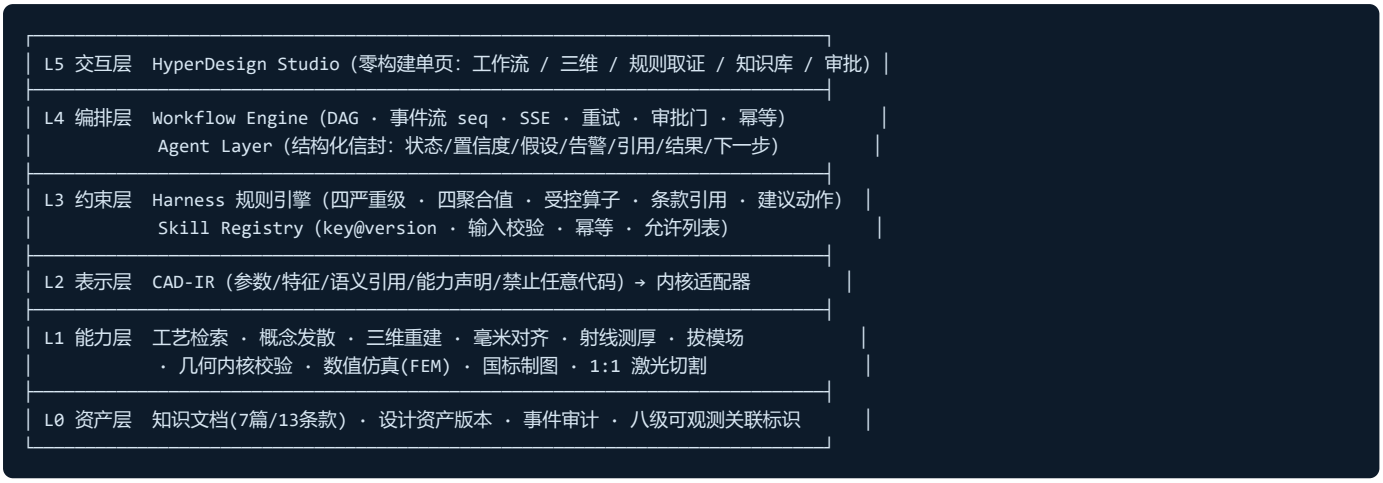
一、为什么需要 2.0：1.0 的三个结构性缺口

1.0 版证明了「概念图→白模→参数化实体→国标图纸」可以端到端跑通，但作为参赛与交付系统，它有三个硬伤：

缺口	1.0 的问题	2.0 的解法
执行不可审计	由大模型直接生成建模脚本并在几何内核里执行——不可复现、换不了内核，且存在任意代码执行风险	**受控几何中间表示（IR）**：模型只产出 JSON，执行体是固定白名单解释器，`execute_script` 一律拒绝
结论不可追溯	可制造性检查是硬编码判断，只有布尔结论，说不出"哪条规范、实测多少、差多少、怎么改"	**准入规则引擎**：规则携带规范文档与条款原文、实测值/限值/单位、整改建议与阻断语义
过程不可观测	线性脚本 + 文本日志，没有阶段状态、没有审批门、失败无法定位到节点	**工作流引擎**：持久化 DAG、单调序号事件流、SSE 推送、人工审批门、断点续跑与幂等

补充两个能力缺口：1.0 没有**仿真**（无法回答"够不够强"），也没有**知识资产**（工艺规范写死在代码里）。2.0 一并补齐：自研有限元求解器与支持角色隔离的知识库。

二、系统架构：六层 + 五类抽象



2.1 五类抽象（这是 2.0 与"套壳大模型"的根本区别）

抽象	职责边界	落地证据
Agent	只做决策与协调，不做数值计算、不操作内核；输出必须通过信封校验	非法状态、完成但空结果、需输入却无下一步——三类都被拒绝
Skill	版本化确定性执行体，输入必填字段校验、幂等、超时	6 个技能；未知技能返回 `SKILL_NOT_FOUND`，缺字段返回 `SKILL_INPUT_INVALID`
Harness	判定"当前输入/过程/结果是否允许继续"，不生成设计	3 个规则包 20 条规则，全部带文档与条款引用
CAD-IR	模型与几何内核之间唯一的数据契约	两次重建体积偏差 **0.0000%**；注入 `execute_script` 被拒
Workflow	阶段编排、状态机、审批与审计	6 节点链路；物理不通过时审批门不打开

三、核心能力与实测数据（六道工程门禁，全部可复跑）

每个阶段都有独立门禁脚本与报告，任何人可在本机复跑验证；下表为真实运行结果，不是估算值。

门禁	考的是什么	关键结果	结论
M0 几何表示与解释器	确定性、拓扑合法、尺寸、实测拔模、安全边界	体积偏差 **0.0000%**；包络 **120.0×80.0×45.0mm**；Z_min=0；**拔模 min 1.8°、零度直壁 0**	**8/8 通过**
M1 准入规则与智能体	规则可审计、裁决四值、缺失即无效、越权拦截	17 条规则全带引用；白模被判不通过（薄壁 **1.51mm < 2.4mm**）；指标缺失判 **invalid**；非法算子被拒	**13/13 通过**
M2 工作流与事件流	审批不可绕过、断点续跑、幂等、事件可回放	物理不通过→审批节点 **skipped**；12 条事件 seq 单调可补拉；重复运行被拒	**8/8 通过**
M3 交互界面	真浏览器端到端、三维显示、规则取证、审批闭环	HUD 实测 **120.00×80.00×45.00mm、Z=0.000**；19 条规则取证；审批后状态 succeeded	**9/9 通过**
M4 数值仿真	与理论解对标、网格收敛	梁挠度/弯矩误差 **0.0000%**；圆孔应力集中 **Kt=3.128**（理论 3.0，误差 4.25%）	**7/7 通过**
M5 知识资产	混合检索、引用溯源、角色隔离、无证据拒答	三角色可见 **1/6/7** 篇；命中即带 **2.4/1.44/1.8°** 条款；无关查询 **found=false**	**10/10 通过**

3.1 端到端链路（6 节点工作流）

① 几何中间表示构建 → ② CAD 几何准入（B-Rep 合法性 / 三向包络 / 基准面 / 实测拔模）→ ③ 网格物理准入（射线测厚 p10 / 拔模场 / 水密 / 包络漂移）→ ④ 数值仿真（导光孔应力集中）→ ⑤ 仿真准入（结果是否已对标 / 应力区间 / 许用值）→ ⑥ 人工验收门。任一层判失败或无效，后续节点与审批门立即阻断。

四、四个真实应用场景

① 注塑结构件敏捷开发

输入功能描述与包络，自动注入企业规范（壁厚 2.4mm / 筋 1.44mm / 拔模 1.8°），产出通过几何校验的 STEP 与 A3 工程图。

实测：首轮通过，包络偏差 0，体积 69,042.2mm³

② 钣金与激光切割件排产

自动剥离图框与尺寸线，输出 1:1 纯净外轮廓与孔位的激光切割文件。

实测：TOP 轮廓 82 条，仅切割图层

③ 非标零部件系列化派生

交付参数化几何中间表示而非死模型，改参数即派生同族规格，图纸与工艺约束同步。

实测：两次重建体积偏差 0.0000%

④ 跨部门免插件协同审阅

零构建单页，浏览器内三维旋转、线框检查、Z 轴剖切、包络核对与一键提交。

实测：一次提交归档 3 条偏好样本

五、六个创新点

1. **几何真实优先的跨模态尺寸锚定**：以白模三层高度（10%/50%/90%）截面采样作为草图尺寸锚点，把美学比例翻译为可校验的尺寸约束，最终实体包络与目标偏差为 0。
2. **受控几何中间表示 + 自愈闭环**：模型只产出数据、不执行代码；内核返回拓扑/体积/包络误差作为硬判据，失败回传诊断并最多自愈五轮，失败与成功样本同时进入偏好数据。
3. **客观物理信号优于视觉评分的三级评判**：射线测厚与拔模场作为第一关，通过后才进入视觉语言模型评分与人工终审；白模因薄壁 1.51mm、拔模 0.84°、非水密被判不通过，系统改走"白模仅作锚点、实体按铁律重建"路径。
4. **工艺知识、规则与证据一体化**：每条规则裁决都带文档、条款原文、实测值与建议动作；知识检索设证据门控，无证据即拒答，把"凭印象回答"改造成"凭证据裁决"。
5. **自研数值仿真并强制对标**：无外部求解器依赖，梁单元对等截面梁为精确解（误差 0.0000%），带孔板应力集中与经典解误差 4.25%；未通过对标的结果不得作为设计依据。
6. **零边际成本的偏好进化与守门员**：设计选择与自愈记录自动成为偏好样本；模型迭代必须通过黄金基准回归，未全面超越即禁止切流（实测样本不足时守门员判定 0/1，正确阻止上线）。

六、与同类方案的对比

能力	同类平台（参考 Gitee 公开实现）	HyperDesign 2.0
智能体/技能/准入抽象	有（Agent/Skill/Harness 声明）	**同等严谨，且规则带条款引用与实测证据**
几何中间表示	声明式 IR，禁止脚本执行	**IR + 几何锚点 + 实测拔模场；任意代码注入被拒**
工作流与审批	节点状态机 + 人工审批	**DAG + 事件流 seq/SSE + 物理否决 + 幂等续跑**
知识资产	混合检索 + 权限	**混合检索 + RBAC + 证据门控（无证据拒答）**
仿真	外部求解器（需装编译链）	**自研 FEM，零依赖，强制与理论解对标**
生成式造型	**无（模板参数驱动）**	**概念发散 → 三维重建 → 毫米对齐 → 可制造实体**
物理可制造性	**规则阈值**	**射线测厚 p10 + B-Rep 拔模场实测**
模型自进化	**无**	**偏好样本自动归档 + 基准回归守门员**

七、落地可行性

- **单机离线**：一张 16GB 消费级显卡 + Windows/WSL 双环境，全部推理与几何计算本地执行，断开外网可完整运行，无云端 API。
- **零构建前端**：交互层为静态单页（本地 vendored 三维库），无 npm 构建链，拷走即用。
- **标准格式交付**：STEP / DXF / PDF 直接进入既有 CAD、CAM 与质检流程，不改变企业现有工具链。
- **数据合规**：文档与资产不出内网；知识库按角色隔离；运行产生带序号的审计事件；产物下载做文件名白名单与路径规范化；智能体工具调用采用允许列表。
- **可复制性**：换行业只需替换知识文档与规则包，不改代码；所有门禁脚本可复跑，验收标准客观。

八、已知限制（如实披露）

1. **生成式白模本身不可直接制造**：单图重建的网格不水密、壁厚与拔模不可控，系统将其降级为"造型比例参考"，制造实体由受控建模按工艺铁律重建——这正是三级评判存在的意义。
2. **偏好进化需要样本量**：本次仅 3 条偏好样本做机制验证，进化模型在基准题上一通过率为 0/1，守门员据此禁止切流；按规范需积累 50~100 条再做正式进化。
3. **部分规划组件在本机不可用**：建模库的原生扩展无法加载，改用同一开源几何内核的宿主程序；检索与求解改为自研实现。替换原因与验证结果逐条记录在仓库 `issues.md`（24 条）。
4. **市场与成本数据尚缺第三方核验**：材料中的市场判断为定性分析，量化收益需在试点客户处标定后再补充。

九、参考与依据

1) Structured 3D Latents for Scalable and Versatile 3D Generation， arXiv:2412.01506； 2) M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings， arXiv:2402.03216； 3) FLUX.2: Frontier Visual Intelligence， Black Forest Labs， 2025； 4) Flexible Isosurface Extraction for Gradient-Based Mesh Optimization， arXiv:2308.05371； 5) Direct Preference Optimization， arXiv:2305.18290；6) QLoRA， arXiv:2305.14314；7) Rectified

Flow，arXiv:2209.03003； 8) GB/T 14665《机械工程 CAD 制图规则》、GB/T 1804《一般公差 未注公差的线性和角度尺寸的公差》； 9) Open CASCADE Technology、FreeCAD、ezdxf、three.js、Unsloth 官方文档。

所有数字均由本机门禁脚本产出，原始报告见 `docs/poc/M0~M6-GATE-REPORT.md`；界面截图见 `docs/poc/shots/`；演示视频见 `docs/demo/`。